

InfiData 数据转换交接文档

1. 大体背景与介绍

本项目完成两步转换：

```
1  源机器人数据
2    -> scripts/convert/convert_*.py
3  InfiData 中间格式
4    -> scripts/convert2openpi/convert_infidata_*_to_rlds.py
5  RLDS格式数据
```

为什么需要分两步转换？

- 源数据的格式多种多样，先转换为统一的InfiData格式，便于后续管理
- RLDS格式的数据是直接用于训练的
- 因此，InfiData格式的数据是中间层数据。例如，数据标注等工作，就可以直接在统一的中间层InfiDATA上做
- 而RLDS是导出训练时所需要的。注意，不同的训练可能需要不同的字段，因此，针对最终训练的具体情况，去从中间层数据上跑脚本，导出得到RLDS

InfiData

InfiData 以 episode 为单位保存。每个 parquet 行对应一帧，包含 state、action、任务文本、质量信息和视频帧索引。

```
1  <infidata-root>/
2  |— data/<dataset>/chunk-xxx/episode_xxxxxx.parquet
3  |— meta/
4  |   |— episodes.jsonl
5  |   |— segments.jsonl
6  |   |— tasks.json
7  |   |— robots.json
8  |   |— stats.json
9  |— videos/
```

RLDS

RLDS 产物是标准 TFDS 数据集。一个 TFDS example 对应一个 episode：

```

1 episode
2   └─ steps: tf.data.Dataset
3     └─ observation.state: float32[state_dim]
4       └─ observation.images: {camera: uint8[H,w,3]}
5         └─ action: float32[action_dim]
6           └─ task / subtask / quality / success / mistake
7             └─ reward / discount
8               └─ is_first / is_last / is_terminal
9             └─ episode_metadata

```

磁盘结构为：

```

1 <rlDs-root>/<variant>/<builder>/<version>/
2   └─ dataset_info.json
3     └─ features.json
4       └─ <builder>-<split>.tfrecord-*

```

数据集	Builder	版本
DROID	droid_infidata	1.1.0
RoboCOIN	robocoin_infidata	1.0.0
RoboMIND full	robomind_full_infidata	1.0.0
AgiBot	agibot_infidata	1.0.0
EgoVerse	ego_verse_infidata	1.0.0
realworld_piper	realworld_piper_infidata	1.0.0

不同 state/action 维度、fps 或相机集合会拆成不同 variant。数据会按比例生成 `train`、`unseen_test` 和 `seen_test`；其中 `seen_test` 是 `train` 的子集。以版本目录中的 `dataset_info.json` 作为转换成功标志。

2. 具体的可复现命令

所有命令从仓库根目录运行。

```

1 cd /mnt/workspace/wudi/InfiData-personal

```

环境安装：

```

1 python -m pip install \
2     numpy pandas pyarrow tqdm h5py jsonschema opencv-python \
3     tensorflow tensorflow-datasets av pillow
4
5 ffmpeg -version
6 ffprobe -version

```

下述命令默认全量转换。可通过修改`--num_episodes`限制最大的转换条数

2.1 DROID

```
1 # 源数据 -> InfiData
2 python scripts/convert/convert_droid.py \
3     --droid_root /mnt/workspace/wudi/ELUBrain/DROID \
4     --out_root /mnt/workspace/InfiData/DROID \
5     --num_episodes 0 \
6     --overwrite
7
8 # 校验
9 python scripts/validate/validate_robot_dataset.py \
10    /mnt/workspace/InfiData/DROID \
11    --report /mnt/workspace/InfiData/DROID/validation_report.json
12
13 # InfiData -> RLDS
14 python scripts/convert2openpi/convert_infidata_droid_to_rlds.py \
15     --infidata-root /mnt/workspace/InfiData/DROID \
16     --lrobot-root /mnt/workspace/wudi/ELUBrain/DROID \
17     --data-dir /mnt/workspace/RLDS/DROID \
18     --overwrite
```

DROID RLDS 仍需要原始 DROID 目录，用于从共享视频中准确解码 episode 帧。

2.2 RoboCOIN

```
1 # 源数据 -> InfiData
2 python scripts/convert/convert_robocoin.py \
3     --robocoin_root /mnt/workspace/wudi/ELUBrain/RoboCOIN_data/RoboCOIN \
4     --out_root /mnt/workspace/InfiData/RoboCOIN \
5     --num_episodes 0 \
6     --overwrite
7
8 python scripts/validate/validate_robot_dataset.py
9 /mnt/workspace/InfiData/RoboCOIN
10
11 # InfiData -> RLDS
12 # 每个 .sh 对应一个 variant; 先查看可用脚本
13 ls scripts/convert2openpi/RoboCOIN/*.sh
14
15 # 示例: Airbot MMK2
16 INFIDATA_ROOT=/mnt/workspace/InfiData/RoboCOIN \
17 RLDS_ROOT=/mnt/workspace/RLDS/RoboCOIN \
18 bash
19 scripts/convert2openpi/RoboCOIN/Airbot_MMK2_s36_a36_fps30__episodes_10532.sh
```

2.3 RoboMIND

源数据已有四个分片 wrapper:

```
1 # 源数据 -> InfiData
2 for shard in 0 1 2 3; do
```

```

3   ROBOMIND_ROOT=/mnt/workspace/wudi/ELUBrain/RoboMIND \
4   OUT_ROOT=/mnt/workspace/wudi/InfiData/RoboMIND_shard_${shard} \
5
6   EXTRACT_ROOT=/mnt/workspace/wudi/ELUBrain/RoboMIND_extracted_shards/shard_${shard} \
7   OVERWRITE=1 \
8   bash scripts/convert/convert_robomind_shard${shard}.sh
9 done
10
11 for shard in 0 1 2 3; do
12     python scripts/validate/validate_robot_dataset.py \
13         /mnt/workspace/wudi/InfiData/RoboMIND_shard_${shard}
14 done
15
16 # InfiData -> RLDS
17 # 每个 .sh 对应一个 variant: 先查看可用脚本
18 ls scripts/convert2openpi/RoboMIND_full/*.sh
19
20 # 示例: UR5e
21 INFIDATA_ROOT=/mnt/workspace/wudi/InfiData \
22 RLDS_ROOT=/mnt/workspace/RLDS/RoboMIND_full \
23 bash
24 scripts/convert2openpi/RoboMIND_full/ur5e_master_puppet_joint_position_h5_ur_1rgb_real_s7_a7_fps30_cam_top_episodes_26380.sh

```

2.4 AgiBotWorld-Beta

```

1 # 源数据 -> InfiData
2 python scripts/convert/convert_agibot_modelscope.py \
3     --agibot_root /mnt/workspace/wudi/ELUBrain/AgiBotWorld-Beta-ModelScope-500h-extracted \
4     --metadata_root /mnt/workspace/wudi/ELUBrain/AgiBotWorld-Beta-ModelScope-500h \
5     --out_root /mnt/workspace/InfiData/AgiBotWorld-Beta-ModelScope-500h \
6     --num_episodes 0 \
7     --overwrite
8
9 python scripts/validate/validate_robot_dataset.py \
10     /mnt/workspace/InfiData/AgiBotWorld-Beta-ModelScope-500h
11
12 # InfiData -> RLDS
13 # 运行现有 AgiBot variant
14 INFIDATA_ROOT=/mnt/workspace/InfiData/AgiBotWorld-Beta-ModelScope-500h \
15 RLDS_ROOT=/mnt/workspace/RLDS/AgiBot \
16 bash scripts/convert2openpi/AgiBot/*.sh

```

2.5 realworld_piper

```
1 # 源数据 -> InfiData
2 python scripts/convert/convert_realworld_piper.py \
3   --source_root /mnt/workspace/InfiData/realworld_piper \
4   --out_root /mnt/workspace/InfiData/realworld_piper_infidata \
5   --num_episodes 0 \
6   --overwrite
7
8 python scripts/validate/validate_robot_dataset.py \
9   /mnt/workspace/InfiData/realworld_piper_infidata
10
11
12 # InfiData -> RLDS
13 # 查看可用 variant
14 python scripts/convert2openpi/convert_infidata_realworld_piper_to_rlds.py \
15   --infidata-root /mnt/workspace/InfiData/realworld_piper_infidata \
16   --list-schemas
17
18 # 示例: 30 FPS、四相机、包含 EE pose 的 variant
19 python scripts/convert2openpi/convert_infidata_realworld_piper_to_rlds.py \
20   --infidata-root /mnt/workspace/InfiData/realworld_piper_infidata \
21   --schema-key piper_s14_a14_fps30_c4_ee_pose \
22   --camera-set cam_front,cam_high,cam_left_wrist,cam_right_wrist \
23   --data-dir
24   /mnt/workspace/RLDS/realworld_piper/piper_s14_a14_fps30_c4_ee_pose \
25   --overwrite
```

2.6 EgoVerse

当前目录只有 EgoVerse 的 InfiData 到 RLDS 转换器，没有源数据到 InfiData 的脚本。

每个 wrapper 对应一个 variant:

```
1 # InfiData -> RLDS
2 ls scripts/convert2openpi/EgoVerse/*.sh
3 ls scripts/convert2openpi/EgoVerse_full/*.sh
4
5 # 示例: 单目录 aria_bimanual
6 INFIDATA_ROOT=/mnt/workspace/InfiData/EgoVerse \
7 RLDS_ROOT=/mnt/workspace/RLDS/EgoVerse \
8 bash scripts/convert2openpi/EgoVerse/aria_bimanual__episodes_625.sh
9
10 # 示例: 三个 full shard 中的 aria_bimanual
11 bash
12   scripts/convert2openpi/EgoVerse_full/aria_bimanual_front_1__episodes_1031.sh
```

3. 转换新数据集应该怎么跑

3.1 源数据转 InfiData

参考结构最接近的 `scripts/convert/convert_*.py` :

1. 读取源 episode、state、action、任务和视频。
2. 每个 episode 写一个 parquet, `frame_index` 从 0 连续递增。
3. 写出 `episodes.jsonl`、`segments.jsonl`、`tasks.json`、`robots.json` 和 `stats.json`。
4. 视频字段统一为 `video.<camera>.path/frame_index`。
5. 先转换 1 至 3 个 episode 并运行校验器。

```
1 python scripts/convert/convert_<dataset>.py \  
2   --source_root /path/to/raw-data \  
3   --out_root /path/to/InfiData/<dataset> \  
4   --num_episodes 3 \  
5   --strict \  
6 \  
7 python scripts/validate/validate_robot_dataset.py \  
8   /path/to/InfiData/<dataset>
```

3.2 InfiData 转 RLDS

参考结构最接近的 `convert_infidata_*_to_rlds.py`, 实现 TFDS

`GeneratorBasedBuilder`: 从 `episodes.jsonl` 枚举 episode, 从 parquet 读取逐帧数据, 解码视频到 `observation.images`, 并按固定 state/action/image shape 拆分 variant。

```
1 python scripts/convert2openpi/convert_infidata_<dataset>_to_rlds.py \  
2   --infidata-root /path/to/InfiData/<dataset> \  
3   --data-dir /path/to/RLDS/<dataset> \  
4   --max-episodes 1 \  
5   --unseen-test-ratio 0 \  
6   --seen-test-ratio 0 \  
7   --overwrite
```

小样本通过后去掉 `--max-episodes 1` 运行全量。完成后检查 `dataset_info.json` 和 `skipped_episodes.jsonl`。